



به نام خدا



دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر
هوش مصنوعی قابل اعتماد

تمرین سوم

نام و نام خانوادگی	مهدی مختاری
شماره دانشجویی	810101515
تاریخ ارسال گزارش	1405/3/22

فهرست


3.....	سؤال اول: شبکه های بیزی
3.....	بخش اول
5.....	بخش دوم
9.....	بخش سوم
11.....	بخش چهارم
13.....	سوال دوم: علّیت
13.....	بخش اول: سوالات تعوری
16.....	بخش دوم: سوالات پیاده سازی
26.....	مراجع

سؤال اول: شبکه های بیزی

بخش اول

زیربخش اول:

الف) شبکه بیزی (Bayesian network) در شکل 1 آمده است.



شکل 1. شبکه بیزی

زیربخش دوم:

از آنجایی که میدانیم در شبکه بیزی احتمال توام (joint prob) برابر احتمال هر گره به شرط فرزندانش است و در صورتی که فرزند نداشته باشد احتمال خودش است. در نتیجه احتمال توام به صورت زیر است.

$$P(W, E, P, A, M, O, H) = P(W) P(E) P(P | W, E) P(A | P) P(M | A) P(O | A) P(H | M, O, P)$$

زیربخش سوم:

Markov blanket در شبکه های بیزی برای یک گره به این صورت تعریف میشود که عملاً تمامی گره هایی است که اگر ما همه مقادیر آنها برای ما given باشند دیگر گره و متغیر مورد نظر به شرط آنها دیگر از همه متغیرهای دیگر مستقل میشود. این گره ها عملاً میشوند:

- گره های فرزند
- گره های والد
- گره های تمامی والد های دیگر فرزندان


نود مورد نظر ما میشود.

به همین خاطر پس برای متغیر $\{A, H, O, P\} = M$ میشود Markov blanket آن.

زیربخش چهارم:

الف) بله - A و W به شرط داشتن P از هم مستقل هستند (به علت پیروی از قانون شکل 3).


► Head-to-tail at a node $Z \in C$



شکل 3. قانون اول استقلال

ب) بله - O و M به شرط داشتن A از هم مستقل هستند (به علت پیروی از قانون شکل 4).

► Tail-to-tail at a node $Z \in C$



شکل 4. قانون دوم استقلال

پ) خیر - زیرا یک مسیر از A به H توسط P وجود دارد که بلاک نشده است. پس در نتیجه این دو به هم وابسته هستند حتی در صورت داشتن O و M.

ت) بله - زیرا طبق شکل 3 تنها مسیری که از E به M میرسد توسط A فراهم میشود که بلاک شده است.

ث) بله - زیرا طبق شکل 3 تنها مسیری که از W به O میرسد توسط A فراهم میشود که بلاک شده است.

بخش دوم

الف) در شکل 5 آمده است.

الف)

$$E \rightarrow E \rightarrow W$$

$$(-) \times (+) = (-)$$

$$P(W' < F') < P(W' | F')$$

و $P(W')$ یک میانگین دارد از عبارت بالا میسر:

$$P(W') < P(W' | F')$$

شکل 5

ب) در شکل 6 آمده است.

Subject :

Year . Month . Date . ()

$$H \xrightarrow{+} E \xleftarrow{-} F$$

$$P(e' | h', f) > P(e' | h'', f) \quad (ب)$$

$$P(e' | f', h) < P(e' | f'', h)$$

از آنجایی که $P(f' | e')$ را داریم و عملاً اگر بدانیم e رخ داده (۱) چون رابطه

مغایر دارد با F پس احتمال f'' بزرگتر شود. حالا اگر (مسلماً مستقیم است)

بدانیم h' مستقیم است یعنی f'' بزرگتر شود و به عبارت دیگر $P(f' | e') > P(f'' | e')$

و از آنجایی که رابطه با برتری است $P(f' | e') < P(f'' | e')$

CS Scanned with CamScanner

شکل 6.

پ) در شکل 7 آمده است.

$$(c) \quad \underline{P(h' | w')} > P(h' | f', w') \quad \text{از آنجایی که } f' \text{ از } h' \text{ بهتر است}$$

given ~~$P(h' | w')$~~ ~~$P(h' | f', w')$~~ ~~$P(h' | w')$~~

چنین نیست که احتمال h' کمتر شود زیرا فرد f' در حالتی قرار دارد

که باعث ایجاد ابهام می‌شود و در نتیجه احتمال h' بیشتر می‌شود.

به سادگی می‌توان دید که این درست است.

CS Scanned with CamScanner

شکل 7.

(ت) در شکل 8 آمده است.

Subject :

Year . Month . Date . ()

ت | $P(e'|w')$ را در تقاطع w' و e' می بینیم

c' را می بینیم که c' بر e' تأثیر می گذارد

بر e' تأثیر می گذارد. با داشتن c' و w' می توانیم e' را پیدا کنیم

نمی بینیم که w' بر e' تأثیر می گذارد است. c' و w' می توانند e' را تعیین کنند

w' بدون c' که w' را تعیین کند. c' را می توانیم با w' و e' پیدا کنیم

$$P(e'|w') < P(e'|w', c')$$

شکل 8.

ث) در شکل 9 آمده است.


ع | $P(w', e', c')$ را در تقاطع w' ، e' و c' می بینیم

می بینیم که w' و c' بر e' تأثیر می گذارد

از w' و c' که e' را تعیین کنند $H \perp w' | D, E$ و $P(w', e', c')$

شکل 9.

د) در شکل 10 آمده است.



شکل 10.

بخش سوم

زیربخش اول:

n متغیر داریم که هر کدام L مقدار مختلف میتوانند بگیرند. پس یک جدول داریم که ستون های آن این n متغیر باشد و از انجایی که هر کدام L مقدار بگیرند در نتیجه L^n مقدار مختلف باید محاسبه شود تا بتوان احتمال توام را بدست آورد. البته از انجایی که نوشته شده عدد دقیق چون جمع احتمال ها باید 1 بشود پس احتمال اخر را نیازی نیست محاسبه کنیم. در نتیجه L^{n-1} پارامتر مستقل باید محاسبه شود.


زیربخش دوم:

در واقع از انجایی که برای محاسبه احتمال توام صرفا کافی است که هر گره به شرط والد هایش در رابطه ضربدر بقیه شود. باید هر کدام از این احتمال ها را دید با چند مقدار مستقل میتوان بدست آورد. برای هر کدام در صورت داشتن حداکثر k والد و هر کدام میتوانند L مقدار داشته باشند پس $L^k * (L-1)$ مقدار مستقل را باید حساب کرد (علت $L-1$ هم خود متغیری است که داریم احتمال ان را حساب میکنیم به غیر

از والد ها خودش L مقدار میگیرد و مقدار آخری ان به ازای دانستن هر کدام از والد ها را نیاز نیست محاسبه کنیم زیرا جمع احتمال ها چون 1 است بدست می آید.

حال ما n متغیر مختلف داریم و برای هر کدام این تعداد $((L-1)*L^k)$ مقدار مستقل بدست آوریم به احتمال تو ام میتوانیم برسیم. در نتیجه در کل با مقدار کران بالا (چون حداکثر والد ها را گرفتیم) با $n * (L-1)*L^k$ مقدار مستقل میتوان به احتمال توام رسید.

زیربخش سوم:



$$P(C, X_1, X_r, X_c, \dots, X_n)$$

$$= P(C) \times P(X_1 | C) \times P(X_r | C, X_1) \times P(X_c | X_r, C) \times \dots \times P(X_n | X_r, C)$$

$P(C) :$ مقدار $m-1$ ✓

$P(X_1 | C) :$ مقدار $m \times (L-1)$ ✓

نیاز به والدی هر متغیر مستقل مقدار L^{k-1} که X_1 بگیرد
بسیار کم است و محاسبه ندارد.

$P(X_r | X_1, C) :$ مقدار $m \times L \times (L-1)$ ✓

i

والد متغیر X_i مقدار L^{k-1} دارد و X_i به X_{i+1} مقدار L^{k-1} میدهد.

اما متغیر X_n به X_{n+1} مقدار L^{k-1} میدهد و X_{n+1} مقدار L^{k-1} میدهد.

در کل: $m-1 + m(L-1) + (n-1)mL(L-1)$

بسیار ساده و راحت محاسبه کنیم

$$= mL + (n-1)mL(L-1) - 1$$


$$= mL(1 + (n-1)(L-1)) - 1$$

شکل 11. تعداد دقیق مقادیر مستقل که باید محاسبه کنیم برای احتمال توام

بخش چهارم

زیربخش اول:



جواب برای کراف سمت راست در شکل 12 و جواب برای گراف سمت چپ در شکل 13 آمده است.




$$I(G) = \{A \perp C | B, E \perp C | D, B \perp D, B \perp E, A \perp D, A \perp E\}$$

در اینجا یک گراف G' که $I(G') = I(G)$ است که I -equivalent است.

۳ گراف I -equivalent به هم دارند که در اینجا به (ب) :



شکل 12. گراف سمت راست



$$I(G) = \{ A \perp C, A \perp D \mid B, A \perp E \mid B, \\ A \perp E \mid D, B \perp E \mid D, \\ C \perp D \mid B, C \perp E \mid B, \\ C \perp E \mid D \}$$



Scanned with CamScanner

معادل I-معادل

شکل 13. گراف سمت چپ

زیربخش دوم:

خیر - زیرا تنها DAG هایی که میتوانند باعث برقراری شرط اول که A مستقل است از B به شرط داشتن C یکی از 3 حالت زیر است:

$$A \rightarrow C \rightarrow B$$

$$A \leftarrow C \leftarrow B$$

$$A \leftarrow C \rightarrow B$$

که هیچ کدام از این ها شرط A مستقل از B را ایجاب نمیکنند و بلکه در همه این حالات این دو متغیر به تنهایی به هم وابسته هستند. فلذا هیچ perfect map برای توزیع بالا نمیتوان رسم کرد.

سوال دوم: علّیت

بخش اول: سوالات تعوری

زیر بخش اول: نامساوی

سوال 1) اثبات مورد اول در شکل 14 و مثال نقض دومی در شکل 15 آمده است.

دلیل درست بودن عبارت اول گفته شده:

$$\min_n P(y|n) \leq P(y) \leq \max_n P(y|n)$$

دلیل 2 که $\sum P(y|n)P(n) = P(y)$ از آن جایی که $\sum P(n) = 1$ است پس

مطابق $P(y)$ از $\sum P(y|n)P(n)$ مقدار معادلی صادر می شود.

شکل 14. اثبات برقرای نامساوی اول

Subject :

Year . Month . Date . ()

$$\text{اگر } X \rightarrow Y \text{ ، } P(X | do(Y)) = P(X)$$

$$\text{اگر } Y \rightarrow X \text{ ، } P(X | do(Y)) = P(X | Y)$$

۱. در آن جایی که $P(Y)$ یکنواخت در $P(Y | do(X))$ نیست ، فلذا شوم ندارد پس آن

۲. مقدار ماکسیمم J

[برای حالت با پیروی افغانیم]

$$\begin{aligned} \text{مثلا } P(Y=1) &= 0.9 \text{ من بزرگتر باشد با (مثلا)} \\ P(Y | do(X=1)) &= 0.4 \\ P(Y=0) &= 0.1 \\ P(Y | do(X=0)) &= 0.6 \end{aligned}$$

$$0.9 = P(Y=1) > \max P(Y | do(X)) = 0.6$$

$$0.1 = P(Y=0) < \min P(Y | do(X)) = 0.6$$

پس در هر دو حالت برقرار نیست ، پس به کمک نقض برهان (مردم و طبق هیچ ربطی ندارد)



Scanned with CamScanner

نقشه من لیبر دارد .


شکل 15. مثال نقضی برای رد نامساوی دوم

زیربخش دوم: اثر علی

$E[M | L, A]$ اثر علی $cpu\ load$ را روی $Memory\ usage$ نشان میدهد. دلیل آن در شکل 16 به

تفصیل بیان شده است.

causal model (SCM) - Structural causal model
 causal model (SCM) - Structural causal model
 (مبتدا - 2) - 2 (مبتدا - 2)
 (مبتدا - 2) - 2 (مبتدا - 2)



که M را در مورد $E[M|A]$ می بینیم (که M را در مورد $E[M|A]$ می بینیم)

$E[M|L, A]$ (که M را در مورد $E[M|L, A]$ می بینیم)

Scanned with CamScanner


بخش دوم: سوالات پیاده سازی

زیربخش اول: پیاده سازی SCM

کلاس را پیاده سازی کردیم. در نوت بوک میتوانید کد کلاس SCM را ببینید.

زیربخش دوم: تاثیر دوره آموزشی

الف) کد آن را زدیم و نمودار گراف علی ان را رسم کردیم. (در شکل 17 آمده است).



شکل 17. Causal graph خواسته شده کشیده شده

ب) observational difference - مقایسه موفقیت یک دانش آموز در صورتی که در دوره شرکت کرده باشد یا نکرده باشد است که عدد 6 همانطور که در شکل آمده است محاسبه کردیم. دلیل این عدد

بالا این است که ما صرفاً میبینیم تفاوت عملکرد انهایی که رفتند دوره و نرفتند چه است و این موضوع بدون در نظر گیری بحث انگیزه است که خود میتواند جدای از دوره باز به بیشتر شدن این نمره و تراز آزمون منجر شود. این موضوع یک همبستگی اماری است و نه یک اثر علی. پس چون اثر علی نیست ما نمیتوانیم با استفاده از این داده بدست آمده نتیجه گیری راجب میزان مفید بودن دوره بکنیم. بلکه باید مورد ج را انجام بدهیم و do بزنیم.

=====

(b) OBSERVATIONAL DIFFERENCE

=====

$$\begin{aligned} E[Y \mid X=1] &= 4.5019 \\ E[Y \mid X=0] &= -1.6911 \\ E[Y|X=1] - E[Y|X=0] &= 6.1930 \end{aligned}$$

شکل 18. Observational difference value calculated

ج) **interventional difference** – در این حالت اثر علی واقعی را خواهیم دید که با به حالت شرطی اما با do است که مجبور میکنیم افراد را چه انگیزه دارند چه ندارند دوره را بگذارند و نتیجه را در این حالات بررسی میکنیم که جقدر تراز آزمون آنها که متغیر Y است بهتر میشود. مقدار محاسبه شده در این حالت همانطور که در شکل 18 قابل مشاهده است 3 است که این عدد واقعی میزان تاثیر دوره رفتن در مقابل نرفتن است. همانطور که پیشبینی هم میشد ای ن مقدار بسیار کمتر از آن مقدار قبلی بدست آمده است که اثر انگیزه (همان متغیر U) را در نظر نمیگرفت.

=====

(c) TRUE CAUSAL EFFECT (ATE via do-operator)

=====

$$\begin{aligned} E[Y \mid do(X=1)] &= 3.1059 \\ E[Y \mid do(X=0)] &= 0.0408 \\ ATE &= 3.0651 \end{aligned}$$

شکل 19. True causal effect (ATE)


د) مقدار در حالت **observational** همانطور که گفته شد 6 و در حالت **Interventional** که ما خودمان زور کردیم که ملت دوره را بگذارند 3 بدست آمد. ما عملاً در حالت **observational** نه تنها میزان تاثیر دوره در واقع داشتیم بررسی میکردیم اما به طور ضمنی میزان انگیزه را هم دخیل میدانستیم و تاثیر آن هم در نتیجه می آمد برعکس حالت بعدی که صرفاً تاثیر دوره را اندازه گیری کردیم. دلیل اینکه در حالت اول مقدار عددی بیشتر شد آن بود که کسانی دوره را بیشتر میگذارند که انگیزه بیشتری دارند و

انگیزه بیشتر آنها خود باعث میشود بتوانند تراز بالاتری کسب کنند اما همه این نتایج به حساب دوره دیده میشود با اینکه این صرفاً یک همبستگی است و نه یک علت.

زیربخش سوم: سیگار نکشیم

مدل گفته شده را ساختیم و گراف علی آن را در شکل 20 آورده ایم.

Heart Disease Causal Graph



شکل 20. Causal graph of heart disease

مقدار محاسبه شده ATE 0.08 است. (در شکل 21 آمده است.)

```

# E[Disease | do(Smoking=1)] - E[Disease | do(Smoking=0)] over the whole population
ATE = df_smoke["Disease"].mean() - df_nosmoke["Disease"].mean()
print(f"ATE = {ATE:.4f}")
✓ 0.0s
ATE = 0.0866
  
```

شکل 21. ATE

مقدار محاسبه شده ATT 0.1 است. (در شکل 22 آمده است.)

```

smoker_idx = obs_df[obs_df["Smoking"] == 1].index

scm_smoke_att = scm.do_operator({"Smoking": 1})
scm_nosmoke_att = scm.do_operator({"Smoking": 0})

n_smokers = len(smoker_idx)
df_att_smoke = scm_smoke_att.sample(n_smokers)
df_att_nosmoke = scm_nosmoke_att.sample(n_smokers)

ATT = df_att_smoke["Disease"].mean() - df_att_nosmoke["Disease"].mean()
print(f"ATT = {ATT:.4f} (based on {n_smokers} observed smokers)")
✓ 0.0s
ATT = 0.1021 (based on 405 observed smokers)

```

شکل 22. ATT

مقدار محاسبه شده CATE برای افراد بالای 55 سال 0.12 و برای افراد پایین 55 سال 0.08 است. (در شکل 23 آمده است.)

```

N_cate = 5_000

df_s = scm.do_operator({"Smoking": 1}).sample(N_cate)
df_ns = scm.do_operator({"Smoking": 0}).sample(N_cate)

CATE_old = df_s[df_s["Age"] > 55]["Disease"].mean() - df_ns[df_ns["Age"] > 55]["Disease"].mean()
CATE_yng = df_s[df_s["Age"] <= 55]["Disease"].mean() - df_ns[df_ns["Age"] <= 55]["Disease"].mean()

print(f"CATE (Age > 55) = {CATE_old:.4f}")
print(f"CATE (Age <= 55) = {CATE_yng:.4f}")
✓ 0.1s
CATE (Age > 55) = 0.1209
CATE (Age <= 55) = 0.0842

```

شکل 23. CATE

نتایج کامل هم در شکل 24 در کنار هم تجمیع شده آمده است.

اگر بخواهیم تحلیل داشته باشیم باید بگوییم برای حالت **ATE** چون مقدار مثبت (0.08) است متوجه میشویم به صورت میانگین سیگار کشیدن باعث افزایش ریسک حملات و بیماری های قلبی میشود برای یک انسان رندومن به صورت کلی. (population level causal effect)

حال برای حالت **ATT** باید بگوییم که بین کسانی که سیگار میکشند هم سیگار کشیدن یک تاثیر مثبتی روی احتمال ایجاد بیماری های قلبی میگذارد و این عدد چون 0.1 است یعنی بیشتر از حالت قبلی است نشان میدهد اتفاقا سیگار کشیدن افرادی که سیگاری هستند اتفاقا تاثیری بیشتری روی بیماری های قلبی میگذارد تا انسان های غیر سیگاری (به صورت شهودی هم قابل فهم است زیرا کسانی که سیگاری هستند دچار مشکلاتی تا الان شده اند و ازین به بعد هم بخواهند سیگار بکشند بیشتر احتمال بیماری های قلبی را بالا میبرد پس اگر سیگار را ترک بکنند به بیشتر به سلامت خود دارند کمک میکنند تا افراد عادی)

برای حالت **CATE** از انجایی که تاثیر واقعی و علی (نه صرفا مشاهده ای) سیگار را در حال بررسی هستیم و از انجایی که این عدد برای افراد بالای 55 سال بیشتر است متوجه میشویم که افراد بالای 55 سال با سیگار کشیدن بیشتر مورد احتمال بیماری های قلبی میشوند تا افراد زیر 55 سال. پس اینگونه افراد بیشتر باید رعایت کنند و سیگار نکشند.

Estimand	Value	Interpretation
ATE	0.086646	Effect of smoking on a random person in the population
ATT	0.102137	Effect of smoking on people who actually smoke
CATE (Age > 55)	0.120889	Effect of smoking on older (higher-risk) individuals
CATE (Age ≤ 55)	0.084183	Effect of smoking on younger individuals

شکل 24. جدول تمامی مقادیر خواسته شده به صورت تجمیع شده ("ATE", "ATT", "CATE")

زیربخش چهارم: قالب جدید وب سایت

بخش 1: حالت ساده لوحانه

ضریب مربوط به new layout همانطور که در شکل 25 هم آمده است 2.77- به دست آمده است. منطقی هم هست اگر دقت کنیم از انجایی که مقدار ضریب ثابت رابطه مدل خطی 12 است و حالت layout به صورت باینری آمده است تا توانستیم مدلی خطی روی آن fit کنیم. (حالت old layout مقدار 0 و حالت new layout مقدار 1 را به خود میگیرد.) و اگر مقدار 1 را بگذاریم همان مقدار میانگین برای چیدمان جدید که حدود 9 ثانیه است و اگر 0 بگذاریم همان مقدار میانگین حدود 12 که برای حالت چیدمان قدیم است بدست می آید. منفی بودن این مقدار به این معناست که در حالت چیدمان جدید ملت به صورت میانگین تایم کمتری را روی سایت میگذرانند. (که البته اثبات میکنیم جلوتر که این نتیجه گیری اشتباه است و یک علت دیگری به جز وجود چیدمان جدید و قدیم وجود دارد که سن کسانی است که روی آنها این را تست میکنیم که به صورت خود به خودی افراد با سن بیشتر علاقه به چیدمان قدیم دارند که در حالت کلی تعداد آنها کمتر است اما ما برای تست چیدمان جدید خیلی بیشتر از افرادی که سن بیشتری داریم استفاده کرده ایم.)

```

desc = df.groupby("layout")["time_spent"].agg(["mean", "std", "count"]).round(3)
desc.columns = ["Mean Time Spent", "Std", "N"]
print(desc)
✓ 0.0s

```

layout	Mean Time Spent	Std	N
New_Layout	9.731	4.027	567
Old_Layout	12.502	4.645	433

```

simple OLS regressing time_spent on layout - the unadjusted causal estimate.

df["layout"] = pd.Categorical(df["layout"], categories=["Old_Layout", "New_Layout"])
model = smf.ols("time_spent ~ layout", data=df).fit()
print(model.summary().tables[1])
✓ 0.0s

```


	coef	std err	t	P> t	[0.025	0.975]
Intercept	12.5017	0.207	60.422	0.000	12.096	12.908
layout[T.New_Layout]	-2.7712	0.275	-10.085	0.000	-3.310	-2.232

شکل 26. ضریب بدست آمده برای حالت چیدمان جدید

طبق مقادیر به دست آمده **p , t value** میتوان نتیجه گیری کرد که این مقدار ضریب بدست آمده اصلاً شانس نبوده و از نظر آماری **significant** است. از انجایی که از نظر آماری هم **significant** است یک تحلیلگر آماری ناشی می آید این موضوع را **cause** میداند و نتیجه میگیرد چیدمان جدید علّتی است که باعث شده مقدار **time spent** کم شده است و سریعاً میگوید این پروژه را منحل کنند. (در بخش های بعدی خواهیم دید که چقدر اینگونه تحلیل اشتباه است).


بخش دو: تشخیص بصری)

بله عدم تعادل در سن کسانی که چیدمان جدید و قدیم را دیده اند به وضوح قابل مشاهده است. اهمیت این موضوع به این خاطر است که خود سن افراد یکی از علت های **time spent** برای افراد در سایت است. پس اگر این تعادل در دو حالت جدید و قدیم از نظر سنی برقرار نباشد خیلی نتایج اشتباهی میتوانیم بگیریم.



شکل 27. عدم تعادل مشاهده شده در چیدمان قدیم و جدید از نظر سن

در چیدمان جدید افراد با سن کمتر بیشتر زمان سپری میکنند روی وبسایت ولی در چیدمان قدیم افراد با سن بیشتر کسانی هستند که بیشتر روی وبسایت زمان سپری میکنند.




شکل 28. نمودار جعبه ای

میانگین کل جامعه آماری از آنجایی که تعادل افرادی که شرکت میکنند در تست زمان سپری شده برای چیدمان جدید مانند این توزیع در حالت عادی کسانی که وبسایت را میبینند نیست (یعنی در حالت عادی بیشتر افرادی که به سایت سر میزنند جوان هستند اما در تست ما بلعکس افراد پیر بیشتری برای تست کردن آوردیم) از آنجایی که خود سن افراد هم یک عاملی برای میزان وقت سپری کردن در سایت است در نتیجه میانگین وقتی میگیریم چون به صورت وزن دار نیست در نتیجه نمیتواند تعیین کننده باشد و بیشتر غلط انداز است ما به جای میانگین کل باید میانگین هر دسته را محاسبه بکنیم.

Simpson paradox در این حالت رخ داده است و دلیل و شرح آن در بالا توضیح داده شده است.

بخش سه: مسعله علی)

Website Engagement DAG — age_group is confounder



شکل 29. Website engagement DAG

```

df["layout"] = pd.Categorical(df["layout"], categories=["Old_Layout", "New_Layout"])

model_controlled = smf.ols("time_spent ~ layout + age_group", data=df).fit()
print(model_controlled.summary().tables[1])

```

✓ 0.0s

	coef	std err	t	P> t	[0.025	0.975]
Intercept	4.9332	0.112	44.073	0.000	4.714	5.153
layout[T.New_Layout]	3.0901	0.115	26.787	0.000	2.864	3.316
age_group[T.Young]	10.0836	0.116	87.099	0.000	9.856	10.311

شکل 30. اجرای یک OLS روی چیدمان و سن و با تارگت زمان سپری شده

این سری نه تنها جیدمان را جزو متغیر ها و ویژگی ها آوردیم بلکه سن را هم که طبق گراف علیت میدانیم یکی از علت های میزان زمان سپری شده در سایت است هم استفاده کردیم.

اگر دقت کنیم همانطور که در شکل 30 هم مشخص است ما میدانیم که ضریب در حالت چیدمان جدید در این حالتی که هفت متغیر های تاثیر گذار و علت را گذاشتیم مثبت شده و مقدار آن 3.09 است. این عدد درست است و نشان میدهد که اتفاقا چیدمان جدید باعث میشود ملت حدود 3 دقیقه بیشتر روی سایت زمان سپری میکنند.

همانطور که پیش تر هم گفتیم علامت این ضریب از منفی به مثبت تغییر پیدا کرد. (دلایل آن به صورت کامل در توضیحات ذکر شده است).

توصیه نهایی ما به مدیر محصول این است که این چیدمان جدید خوب و حتما از این استفاده بکند و در صورتی که امکان داشتن چیدمان dual را دارد و همچنین سن کاربران را هم دارد سعی کند به کاربران با سن بالاتر چیدمان قبلی و به کاربران جوان و با سن کمتر چیدمان جدید را نمایش دهد. (اما اگر این امکان را هم نداشت به صورت کلی چیدمان جدید را به عنوان مرجع اصلی روی سایت بگذارد).

بخش چهار: اثبات پایداری و صحت مدل

ضریب چیدمان جدید در حالتی که **Placebo test** انجام می‌دهیم **-0.06** میشود. این ضریب با این مقدار کم نشان می‌دهد که مدل هیچگونه رابطه معنادار خطی بین **چیدمان** و **زمان سپری** شده پیدا نمی‌کند. این دقیقا همان چیزی است که انتظارش را داشتیم زیرا به صورت کامل آن ستون را خراب کردیم (مقادیرش را رنوم شافل کردیم).

	coef	std err	t	P> t	[0.025	0.975]
Intercept	7.4796	0.104	71.705	0.000	7.275	7.684
layout_placebo[T.New_Layout]	-0.0602	0.123	-0.489	0.625	-0.302	0.181
age_group[T.Young]	8.2779	0.123	67.039	0.000	8.036	8.520

شکل 31. اماره های placebo test

اگر کنترل و تعدیل ما معتبر باشد عملا این مقدار ضریب جدید باید 0 یا یک مقدار خیلی نزدیک به صفر باشد زیرا با به صورت رندوم شافل کردن آن متغیر عملا خواص causal آن و تاثیر آن روی متغیر خروجی را از بین برده ایم و مقدار صفر یا نزدیک به صفر یعنی آن ویژگی دیگر تاثیری روی نتیجه که در اینجا time spent است نخواهد داشت.

از آنجایی که **placebo test** به این صورت عمل میکند که یک ویژگی را به صورت رندوم تغییر می‌دهیم و مبینیم ضریب آن چقدر است. در صورتی که این عدد کم بشود و خیلی کمتر باشد در مقایسه با آن چیزی که روی مدل اصلی بدست آمده است نشان می‌دهد که مدل ما بی جهت و بی دلیل این متغیر را به عنوان یک ویژگی تاثیر گذار (حالا چه مثبت چه منفی) در نظر نگرفته است بلکه به صورت کامل یک الگویی بین این ویژگی و مقدار هدف وجود دارد و با انجام این تست میتوان به این نتیجه پی برد و خیالمان را از فرضیه های علیت مان و مدل مان آسوده کرد.

```
Real layout coefficient    : 3.0901
Placebo layout coefficient : -0.0602
Placebo p-value           : 0.6249
```

Placebo near zero and not significant – model is robust.

شکل 32. مقایسه ضرایب بدست آمده در حالت تست و در حالت کنترل شده اصلی

- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.
- Pearl, J., Glymour, M., & Jewell, N. P. (2016). *Causal Inference in Statistics: A Primer*. Wiley.
- Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.
- Pearl, J. (1995). *Causal diagrams for empirical research*. *Biometrika*, 82(4), 669–688.
- Rubin, D. B. (1974). *Estimating causal effects of treatments in randomized and nonrandomized studies*. *Journal of Educational Psychology*, 66(5), 688–701.
- Rosenbaum, P. R., & Rubin, D. B. (1983). *The central role of the propensity score in observational studies for causal effects*. *Biometrika*, 70(1), 41–55.
- Greenland, S., Pearl, J., & Robins, J. M. (1999). *Confounding and collapsibility in causal inference*. *Statistical Science*, 14(1), 29–46.
- Simpson, E. H. (1951). *The interpretation of interaction in contingency tables*. *Journal of the Royal Statistical Society, Series B*, 13(2), 238–241.
- Seabold, S., & Perktold, J. (2010). *Statsmodels: Econometric and statistical modeling with Python*. *Proceedings of the 9th Python in Science Conference*, 57–61.
- Hagberg, A., Swart, P., & Chult, D. (2008). *Exploring network structure, dynamics, and function using NetworkX*. Los Alamos National Laboratory.
- Harris, C. R., et al. (2020). *Array programming with NumPy*. *Nature*, 585, 357–362.
- McKinney, W. (2010). *Data structures for statistical computing in Python*. *Proceedings of the 9th Python in Science Conference*, 56–61.
- Hunter, J. D. (2007). *Matplotlib: A 2D graphics environment*. *Computing in Science & Engineering*, 9(3), 90–95.