

به نام خدا



دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده برق و کامپیوتر



درس: هوش مصنوعی قابل اعتماد

مدرس: دکتر مصطفی توسلی پور

تمرین شماره ۲

اردیبهشت ماه ۱۴۰۵

۳	سوال اول: تفسیرپذیری.....
۳	بخش اول: سوالات توضیحی.....
۳	زیربخش اول: PDP (۱۰ نمره).....
۳	زیربخش دوم: Lime (۴ نمره).....
۴	زیربخش سوم: Shapley values (۷ نمره).....
۴	زیربخش چهارم: NAM (۴ نمره).....
۵	بخش دوم: سوالات پیاده سازی.....
۵	زیربخش اول: مقداردهی مدل (۱ نمره).....
۵	زیربخش دوم: بخش بندی تصویر (۳ نمره).....
۶	زیربخش سوم: تولید نمونه های تغییر یافته (۸ نمره).....
۷	زیربخش چهارم: وزن دهی تصاویر تغییر یافته (۵ نمره).....
۷	زیربخش پنجم: آموزش مدل خطی (۱۰ نمره).....
۸	زیربخش ششم: تصویر خرس قطبی (۳ نمره).....
۹	سوال دوم: توصیف پذیری مدل های هوش مصنوعی با استفاده Grad-CAM.....
۹	بخش اول: Grad-CAM.....
۹	زیربخش اول: پرسش و پاسخ (۳۰ نمره) هر سوال ۷.۵ نمره.....
۱۰	زیربخش دوم: پیاده سازی (۱۵ نمره).....
۱۱	بخش دوم: FinerGrad-CAM.....
۱۱	زیربخش اول: پرسش و پاسخ (۳۰ نمره) هر سوال ۷.۵ نمره.....
۱۲	زیربخش دوم: پرسش و پاسخ (۱۵ نمره).....
۱۲	بخش سوم: مقایسه.....
۱۲	زیربخش اول: مقایسه دو روش (۱۰ نمره).....
۱۳	نکات تحویل.....

سوال اول: تفسیرپذیری

بخش اول: سوالات توضیحی

زیربخش اول: PDP (۱۰ نمره)

تابع Partial Dependence برای مجموعه‌ای از ویژگی‌های S به صورت زیر تعریف می‌شود:

$$PD_S(x_S) = \frac{1}{n} \sum_{i=1}^n \hat{f}(x_S, x_C^{(i)}) \quad 1$$

که در آن $x_C^{(i)}$ مقادیر واقعی ویژگی‌های مکمل C (ویژگی‌هایی که به آن‌ها علاقه‌ای نداریم) در مجموعه داده است.

الف) توضیح دهید اگر S و C همبستگی زیادی داشته باشند، چه مشکلی پیش می‌آید؟

ب) روش Accumulated Local Effects (ALE) اغلب به عنوان راه‌حلی برای مشکل همبستگی ارائه می‌شوند. بطور مختصر ایده روش ALE برای حل این مشکل را توضیح دهید (می‌توانید با خواندن بخش مقدمه مقاله ALE به این بخش پاسخ دهید).

ج) فرض کنید PDP را برای ویژگی X_1 رسم کرده‌اید و یک خط افقی صاف مشاهده می‌کنید. در حالت کلی، آیا می‌توان نتیجه گرفت که مدل برای پیش‌بینی از X_1 استفاده نمی‌کند؟ توضیح دهید.

زیربخش دوم: LIME (۴ نمره)

LIME معمولاً از یک مدل خطی به عنوان جایگزین قابل تفسیر استفاده می‌کند. برای یک مدل جعبه سیاه غیرخطی، تحت چه شرایطی یک تقریب خطی محلی می‌تواند حتی اگر همسایگی به اندازه دلخواه کوچک انتخاب شود، گمراه‌کننده باشد؟ این موضوع چگونه به مفهوم Lipschitz بودن مدل جعبه سیاه مربوط می‌شود؟

زیربخش سوم: SHAPLEY VALUES (۷ نمره)

مقادیر Shapley، توضیح می‌دهند سهم هر ویژگی در اختلاف میان یک پیش‌بینی مشخص و میانگین پیش‌بینی‌ها چگونه است:

$$f(x^i) - \mathbb{E}[f(X)] \quad 2$$

الف) برای یک مدل خطی $f(x) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ ، به صورت مفهومی (بدون ریاضیات سنگین) نشان دهید که مقدار Shapley برای ویژگی j برابر با $\beta_j(x_j^i - \mathbb{E}[X_j])$ است (راهنمایی: نیازی به استفاده از فرمول محاسبه مقدار Shapley برای هر ویژگی نیست؛ از رابطه ۲ و مفهوم توضیحی که روش مقادیر Shapley ارائه می‌دهد استفاده کنید).

ب) یکی از چالش‌های محاسبه مقادیر Shapley یک مدل بصورت جعبه سیاه، پیچیدگی محاسباتی نمایی آن بر حسب تعداد ویژگی‌ها است. با توجه به بخش الف، یک ایده ساده برای تقریب مقادیر Shapley که این چالش را حل کند ارائه دهید.

زیربخش چهارم: NAM (۴ نمره)

مقاله NAM را مطالعه کرده و به سوالات زیر پاسخ دهید:

معماری که این روش پیشنهاد می‌کند را مختصراً توضیح دهید. این معماری چگونه به تفسیرپذیری کمک می‌کند؟ استفاده از این مدل نسبت به استفاده از یک مدل خطی چه مزیتی دارد؟ محدودیت اصلی که استفاده از این روش به همراه دارد چیست؟ در روش PDP، مدل ممکن است مجبور به پیش‌بینی در نواحی از فضای ورودی شود که در داده‌های واقعی وجود ندارند یا در داده‌های آموزشی مشاهده نشده‌اند. آیا NAM این مشکل را کاهش می‌دهد؟

بخش دوم: سوالات پیاده سازی

در این بخش قصد داریم با استفاده از روش LIME، خروجی یک مدل ResNet18 از پیش آموزش دیده شده را تفسیر کنیم. LIME برای تفسیر یک تصمیم محلی در مدل‌های جعبه سیاه به کار می‌رود. در حوزه تصویر، هدف این است که بفهمیم چرا یک مدل یک تصویر خاص را در یک کلاس مشخص (مانند «گربه») طبقه‌بندی کرده است. برای این کار، ابتدا تصویر ورودی به چندین بخش تقسیم می‌شود. سپس با حذف و نگه‌داشتن تصادفی این بخش‌ها، تعداد زیادی نسخه تغییر یافته از تصویر ساخته می‌شود و مدل روی تمام آن‌ها پیش‌بینی انجام می‌دهد. در نهایت، یک مدل خطی ساده روی این نمونه‌ها آموزش داده می‌شود تا مهم‌ترین بخش‌هایی که بیشترین تأثیر را بر تصمیم مدل داشته‌اند شناسایی کند.

نکته: استفاده از کتابخانه‌های آماده پیاده‌سازی LIME مجاز نیست.

زیربخش اول: مقداردهی مدل (۱ نمره)


با استفاده از کد قرار گرفته‌شده در سامانه، مدل ResNet18 را با وزن‌های بارگذاری شده مقداردهی کنید. سپس تصویر "cat.jpg" را بارگذاری کرده و پس از تنظیم ابعاد آن و نرمالسازی، به مدل بدهید.

- با توجه به خروجی، مدل با چه احتمالی این تصویر را متعلق به دسته با اندیس ۲۸۲ (دسته گربه) می‌داند؟

زیربخش دوم: بخش‌بندی تصویر (۳ نمره)

حال لازم است تا تصویر را به بخش‌های تقسیم کنیم. برای این کار، تابعی ساده در فایل کد نوشته شده است.

- با بررسی این کد بطور مختصر توضیح دهید این کد چگونه بخش‌بندی را انجام می‌دهد؟
- تصویر ورودی را به ۱۸ بخش تقسیم کرده و آن را نمایش دهید.




شکل ۱. بخش‌بندی تصویر

زیربخش سوم: تولید نمونه‌های تغییر یافته (۸ نمره)

حال می‌خواهیم نمونه‌های تغییر یافته از تصویر را تولید کنیم. به این منظور:

- بطور تصادفی ۱۰۰۰ آرایه باینری ۱۸ بعدی Z تولید کنید. هر بعد متناظر با یکی از بخش‌های تصویر است. در صورتی که مقدار یک بعد ۱ باشد، یعنی این بخش در این نسخه وجود دارد و اگر ۰ باشد، یعنی این بخش در این نسخه وجود ندارد
- یک تابع بنویسید که با یک آرایه باینری ۱۸ بعدی و تصویر اصلی را به عنوان ورودی بگیرد و تصویر تغییر یافته را خروجی بدهد. به جای بخش‌هایی که در هر نسخه حضور ندارند رنگ میانگین تصویر را قرار دهید.
- با استفاده از تابع فوق، مجموعه تصاویر تغییر یافته را بسازید و چند مورد را نمایش دهید.



شکل ۲. چند نمونه از تصاویر تغییر یافته

زیربخش چهارم: وزن دهی تصاویر تغییر یافته (۵ نمره)

معمولا در روش LIME نمونه‌های تغییر یافته بر اساس فاصله‌شان از تصویر اصلی وزن دهی می‌شوند. سپس حین آموزش مدل خطی هر نمونه متناسب با این وزن در آموزش مدل ظاهر می‌شود (در صورتی که از تابع Lasso.fit کتابخانه sklearn استفاده می‌شود، این کار به سادگی با مقداردهی ورودی sample_weight قابل انجام است).

- بطور مختصر توضیح دهید این وزن دهی به چه منظور انجام می‌شود؟
- کدی بنویسید که با توجه به کد باینری z هر تصویر تغییر یافته، مطابق با فرمول زیر هر نمونه را وزن دهی کند:

$$w(z) = \exp\left(-\frac{[\text{dist}(z)]^2}{\sigma^2}\right)$$

که $\text{dist}(z)$ فاصله کسینوسی z با تصویر اصلی است و به فرم زیر است:

$$\text{dist}(z) = 1 - \frac{z \cdot 1}{|z| |1| + \epsilon}$$


که در آن 1 برداری با تمام درایه‌های یک است (تصویر اصلی)

مقدار σ به صورت $\sigma = 0.25 \times \sqrt{d}$ تنظیم کنید، که در آن d تعداد کل بخش‌ها است.

زیربخش پنجم: آموزش مدل خطی (۱۰ نمره)

حال می‌خواهیم یک مدل خطی با استفاده از خروجی مدل اصلی روی تصاویر تغییر یافته آموزش دهیم.

- تصاویر تغییر یافته را به مدل اصلی داده و احتمال دسته ۲۸۲ آن‌ها را ذخیره کنید
- یک مدل رگرسیون خطی با L1 Regularization با ضریب ۰.۱ و بدون جمله ثابت (fit_intercept=False) بر روی کد تصاویر تغییر یافته و خروجی مدل اصلی در بخش قبل آموزش دهید.
- بطور مختصر توضیح دهید چرا استفاده از L1 Regularization در روش LIME مفید است؟
- ضرایب مدل رگرسیون خطی آموزش دیده شده را بصورت یک heatmap روی تصویر نمایش داده و خروجی را تحلیل کنید.



شکل ۳. نمودار heatmap اهمیت بخش‌ها

زیربخش ششم: تصویر خرس قطبی (۳ نمره)

روش پیاده‌سازی شده را برای تصویر polarBear.png انجام داده و خروجی را تحلیل و نحوه تصمیم‌گیری مدل اصلی را درباره این تصویر با تصویر قبل مقایسه کنید (دسته مربوط به خرس قطبی اندیس ۲۹۶ است).

سوال دوم: توصیف پذیری مدل های هوش مصنوعی با استفاده

GRAD-CAM

شبکه های عصبی کانولوشنی (CNN) در دهه گذشته به دستاوردهای چشمگیری در حوزه بینایی ماشین رسیده اند و در بسیاری از وظایف از جمله طبقه بندی تصویر، تشخیص اشیاء، توصیف تصویر و پاسخ به پرسش های بصری، عملکردی فراتر از انسان از خود نشان داده اند. با این حال، این موفقیت چشمگیر با چالشی بنیادی همراه است: این مدل ها همچون «جعبه سیاه» عمل می کنند. وقتی یک شبکه عصبی پیچیده با میلیون ها پارامتر تصمیمی می گیرد، فهمیدن اینکه چرا و چگونه به آن تصمیم رسیده است، کار آسانی نیست. این عدم شفافیت زمانی بحرانی می شود که این مدل ها در حوزه های حساسی مانند تشخیص پزشکی، خودروهای خودران، تصمیم گیری های قضایی یا استخدام به کار گرفته شوند جایی که اعتماد به تصمیم مدل بدون درک منطق آن، می تواند خطرناک یا حتی غیراخلاقی باشد.

بخش اول: GRAD-CAM

زیربخش اول: پرسش و پاسخ (۳۰ نمره) هر سوال ۷.۵ نمره

مقاله Grad-CAM را بخوانید و به سوالات زیر پاسخ دهید.


(۱) چرا نویسندگان مدعی هستند که Grad-CAM یک «تعمیم» از CAM است و نه یک روش کاملاً متفاوت؟ این موضوع چه پیامد عملی مهمی برای کاربرد Grad-CAM روی معماری های شبکه عصبی موجود دارد؟

(۲) چرا نویسندگان از تابع ReLU در ترکیب نهایی نقشه های فعال سازی استفاده می کنند؟ اگر این ReLU را حذف کنیم، چه اتفاقی می افتد و این مسئله چه چیزی درباره ماهیت گرادیان های منفی و مثبت به ما می گوید؟

(۳) نویسندگان در آزمایش های خود نشان می دهند که Grad-CAM می تواند سوگیری (bias) در مجموعه داده آموزشی را آشکار کند. این کشف چگونه انجام شد و چرا این کاربرد فراتر از یک کنجکاوی فنی، اهمیت اخلاقی و اجتماعی پیدا می کند؟

۴) چرا نویسندگان روش Guided Grad-CAM را معرفی می‌کنند در حالی که Grad-CAM به‌تنهایی قادر به محلی‌سازی کلاس مورد نظر است؟ این ترکیب چه نقص بنیادی در هر یک از دو روش پایه را برطرف می‌کند؟

زیربخش دوم: پیاده‌سازی (۱۵ نمره)



شکل ۴. روش Grad-CAM


مراحل زیر را انجام دهید:

الف) مدل ضمیمه شده Resnet18 که بر روی [Imagenet-1k دیتاست](#) آموزش داده شده است را لود کنید.

ب) دیتاست Tiny Imagenet را بارگذاری کنید.

ج) بدون استفاده از کتابخانه آماده و با استفاده از pytorch روش gradcam را پیاده‌سازی بکنید. و برای ۵ کلاس انتخابی که مدل درست پیش بینی میکند inference بگیرید. Siliancy map را برای ۵ کلاس نشان دهید. (شکل-۴)

د) مانند مقاله فیلتر Guided Grad-CAM را تولید کنید و مانند شکل-۵ زیر نمایش دهید.



شکل 5. نمونه map های ایجاد شده توسط Grad-CAM

بخش دوم: FINERGRAD-CAM

زیربخش اول: پرسش و پاسخ (۳۰ نمره) هر سوال ۷.۵ نمره

مقاله FinerGrad-CAM را بخوانید و به سوالات زیر پاسخ دهید.

(۱) ادعای محوری مقاله این است که نقص Grad-CAM در طبقه‌بندی Fine-grained نه به دلیل «چگونگی» توضیح، بلکه به دلیل «چه چیزی» که توضیح می‌دهد است. این تمایز فلسفی چه معنایی دارد و چرا نویسندگان معتقدند این بینش به یک راه‌حل ساده‌تر منجر می‌شود؟

(۲) نویسندگان از استعاره بازی پیدا کردن تفاوت (spot-the-difference) برای توضیح ایده Finer-CAM استفاده می‌کنند. این استعاره چه شهودی درباره نحوه کار مغز انسان در تشخیص Fine-grained ارائه می‌دهد و Finer-CAM چگونه این شهود را در سطح ریاضی پیاده‌سازی می‌کند؟

(۳) Finer-CAM یک ضریب قابل تنظیم γ معرفی می‌کند که به کاربر اجازه می‌دهد بین «نمای کلی شیء» و «جزئیات ریز تمایزدهنده» تعادل برقرار کند. چرا این انعطاف‌پذیری ارزشمند است و کاربرد آن در حوزه‌های تخصصی مانند زیست‌شناسی چه پتانسیلی دارد؟

(۴) نویسندگان نشان می‌دهند که Finer-CAM می‌تواند به مدل‌های چندوجهی (multi-modal) مانند CLIP گسترش یابد و قابلیت جالبی به activation faithfulness examination ایجاد کند. این قابلیت دقیقاً چه چیزی را بررسی می‌کند و چرا برای اعتماد به مدل‌های هوش مصنوعی مهم است؟

زیربخش دوم: پرسش و پاسخ (۱۵ نمره)

مراحل زیر را انجام دهید:

- الف) از مدل و دیتاست گفته شده در بخش قبل استفاده کنید. (از همان ۵ تصویر قبلی استفاده کنید)
- ب) بدون استفاده از کتابخانه آماده و با استفاده از pytorch روش FinerGrad-CAM را پیاده سازی کنید. مقدار d مانند مقاله ۳ در نظر بگیرید. Siliancy map را برای ۵ کلاس نشان دهید. برای قسمت ۷ از ۳ مقداری استفاده کنید که تغییرات قابل شهود باشد. و تمامی مپ های تولید شده را نمایش دهید.

بخش سوم: مقایسه

زیربخش اول: مقایسه دو روش (۱۰ نمره)

مپ های تولید شده برای دو روش را در کنار هم نمایش دهید و تحلیل خود را ارائه دهید. (نمره این بخش به نحوه تحلیل شما از مپ های تولید شده محاسبه می شود).

نکته برای سوال دوم)

- * برای هر قسمتی که نیاز به توضیح هست حداکثر یک پاراگراف توضیح دهید.
- * تاکید میشود که قسمت های توصیف پذیری برای پیاده سازی باید بدون استفاده از کتابخانه آماده باشد.

نکات تحویل

- مهلت ارسال این تمرین تا پایان روز "جمعه ۱ خرداد ماه" خواهد بود.
- این زمان قابل تمدید نیست و در صورت نیاز می‌توانید از گریس استفاده کنید.
- در نظر داشته باشید که حداکثر مهلت آپلود تمرین در سامانه تا ۷ روز پس مهلت تحویل است و پس از آن سامانه بسته خواهد شد.
- در صورت وجود سوال و یا ابهام می‌توانید از طریق ایمیل با موضوع TAI_HW2 با تدریس‌یاران آموزشی در ارتباط باشید. توجه کنید که حتماً ایمیل سر تدریس‌یار نیز CC شود.
- حداکثر تعداد صفحات گزارش برای سوال اول: ۱۰ صفحه
- حداکثر تعداد صفحات گزارش برای سوال دوم: ۱۵ صفحه
- لطفاً گزارش، فایل کدها و سایر ضمیمه مورد نیاز را با فرمت زیر در سامانه بارگذاری نمائید:
HW2_[Lastname]_[StudentNumber].zip

- تدریس‌یاران تمرین:

۱. محمدعلی مقیمی

mamoghimi@ut.ac.ir

۲. علی فرتوت

ali.fartout@ut.ac.ir

- سر تدریس‌یار:

محمد گرجی

gorji.mohammad@ut.ac.ir

با آرزوی سلامتی و موفقیت روزافزون